Soft Actor-Critic：采用随机策略的离策略最大熵深度强化学习

Tuomas Haarnoja [1] Aurick Zhou [1] Pieter Abbeel [1] Sergey Levine [1]

摘要

无模型深度强化学习(RL)算法已在多种具有挑战性的决策与控制任务中得到验证。然而，这类方法通常面临两项主要挑战：样本复杂度很高，以及收敛过程脆弱，因而需要细致地调节超参数。这两项挑战严重限制了此类方法在复杂真实场景中的应用。本文提出软 Actor-Critic(SAC)，这是一种基于最大熵强化学习框架的离策略 Actor-Critic 深度强化学习算法。在这一框架中，Actor 在最大化期望奖励的同时最大化熵，即在完成任务的同时尽可能保持行为的随机性。此前基于这一框架的深度强化学习方法主要采用 Q 学习形式。通过将离策略更新与稳定的随机 Actor-Critic 形式相结合，我们的方法在多种连续控制基准任务上达到了当时的先进水平，优于以往的同策略和离策略方法。此外，我们表明，相较于其他离策略算法，所提方法具有很好的稳定性，在不同随机种子下取得了非常接近的表现。

1. 引言

无模型深度强化学习(RL)算法已应用于多种具有挑战性的领域，从游戏(Mnih et al., 2013; Silver et al., 2016)到机器人控制(Schulman et al., 2015)。将强化学习与神经网络等高容量函数近似器相结合，有望实现多种决策与控制任务的自动化，但这些方法在真实场景中的广泛应用仍受到两项主要挑战的阻碍。首先，无模型深度强化学习的样本复杂度通常很高：即使相对简单的任务，也可能需要采集数百万步数据；对于采用高维观测的复杂行为，所需数据还可能多得多。其次，这类方法通常对超参数较为敏感：为了在不同问题中取得良好结果，需要仔细设置学习率、探索常数等参数。这两项挑战严重限制了无模型深度强化学习在真实任务中的应用。

深度强化学习样本效率较低的一个原因是同策略学习。一些常用算法，如 TRPO(Schulman et al., 2015)、PPO(Schulman et al., 2017b)和 A3C(Mnih et al., 2016)，需要为梯度更新采集新样本。随着任务复杂度增加，学习有效策略所需的梯度更新次数和每次更新的样本数都会增加，代价因而迅速上升。离策略算法旨在复用过去的经验。传统策略梯度形式难以直接做到这一点，而基于 Q 学习的方法相对容易实现(Mnih et al., 2015)。然而，将离策略学习与神经网络提供的高维非线性函数近似结合，会给稳定性和收敛性带来重大挑战(Bhatnagar et al., 2009)。在连续状态与动作空间中，这一挑战更加突出，因为 Q 学习中的最大化操作通常要由独立的 Actor 网络完成。该场景下常用的深度确定性策略梯度(DDPG)(Lillicrap et al., 2015)具有较高样本效率，但其训练过程十分脆弱且对超参数敏感，因此难以使用(Duan et al., 2016; Henderson et al., 2017)。

我们研究如何为连续状态与动作空间设计高效、稳定的无模型深度强化学习算法。为此，我们采用最大熵框架，在标准最大奖励强化学习目标中

[1]Berkeley Artificial Intelligence Research, University of California, Berkeley, USA. Correspondence to: Tuomas Haarnoja <haarnoja@berkeley.edu>.

Proceedings of the 35th International Conference on Machine Learning, Stockholm, Sweden, PMLR 80, 2018. Copyright 2018 by the author(s).

Chinese translation | Haarnoja et al., ICML 2018 | CC BY 4.0 | proceedings.mlr.press/v80/haarnoja18b.html

加入熵最大化项(Ziebart et al., 2008; Toussaint, 2009; Rawlik et al., 2012; Fox et al., 2016; Haarnoja et al., 2017)。最大熵强化学习改变了强化学习的目标，但仍可通过温度参数恢复原目标(Haarnoja et al., 2017)。更重要的是，最大熵形式能够显著改善探索和鲁棒性：Ziebart(2010)指出，最大熵策略面对模型误差和估计误差具有鲁棒性；相关研究表明，它能通过获得多样化行为来改善探索 (Haarnoja et al., 2017)。已有工作提出了结合熵最大化的同策略无模型深度强化学习算法(O’Donoghue et al., 2016)，以及基于软 Q 学习及其变体的离策略方法(Schulman et al., 2017a; Nachum et al., 2017a; Haarnoja et al., 2017)。不过，同策略变体仍受到上述样本复杂度问题的限制，而离策略变体在连续动作空间中需要复杂的近似推断过程。

本文表明，可以设计一种兼顾样本效率与稳定性的离策略最大熵 Actor-Critic 算法，我们将其称为软 Actor-Critic(SAC)。该算法能够直接扩展到复杂的高维任务，例如具有 21 维动作的 Humanoid 基准(Duan et al., 2016)；而 DDPG 等离策略方法通常难以在这类任务上取得良好结果(Gu et al., 2016)。SAC 还避免了以往基于软 Q 学习的离策略最大熵方法中，近似推断所带来的复杂性和潜在不稳定性(Haarnoja et al., 2017)。我们先证明最大熵框架下策略迭代的收敛性，再通过近似这一过程，提出可以采用深度神经网络实际实现的 SAC 算法。实验表明，相较于已有同策略和离策略方法，SAC 的性能与样本效率均有显著提升。我们还与同期提出的双延迟深度确定性策略梯度(TD3)算法(Fujimoto et al., 2018)进行了比较，该确定性算法对 DDPG 作出了显著改进。

2. 相关工作

我们的 SAC 算法包含三个关键组成部分：策略网络和价值函数网络相互独立的 Actor-Critic 架构；通过复用已采集数据来提高效率的离策略形式；以及用于促进稳定性和探索的熵最大化。本节回顾采用这些思路的相关工作。Actor-Critic 算法通常基于策略迭代推导而来。策略迭代交替执行策略评估，即计算策略的价值函数，以及策略改进，即利用价值函数获得更好的策略(Barto et al., 1983; Sutton & Barto, 1998)。在大规模强化学习问题中，将任一步骤执行至收敛通常并不现实，因此实际中会联合优化价值函数与策略。此时，策略称为 Actor，价值函数称为 Critic。许多 Actor-Critic 算法采用标准同策略策略梯度形式更新 Actor(Peters & Schaal, 2008)；其中不少方法也考虑策略熵，但将其作为正则项，而非直接将熵最大化(Schulman et al., 2017b; 2015; Mnih et al., 2016; Gruslys et al., 2017)。同策略训练通常能提高稳定性，但样本复杂度较高。

已有研究尝试引入离策略样本和高阶方差缩减技术，在保持鲁棒性的同时提高样本效率(O’Donoghue et al., 2016; Gu et al., 2016)。不过，完全离策略的算法仍具有更高效率。DDPG(Lillicrap et al., 2015)是一种广泛使用的离策略 Actor-Critic 方法，也是确定性策略梯度算法(Silver et al., 2014)的深度版本。它利用 Q 函数估计器实现离策略学习，并由确定性 Actor 最大化该 Q 函数。因此，它既可视为确定性 Actor-Critic 算法，也可视为近似 Q 学习算法。然而，确定性 Actor 网络与 Q 函数之间的相互作用，通常使 DDPG 难以稳定，并对超参数设置敏感(Duan et al., 2016; Henderson et al., 2017)。因此，DDPG 很难扩展到复杂高维任务，而同策略策略梯度方法在这些场景下通常仍能获得最佳结果(Gu et al., 2016)。我们的方法将离策略 Actor-Critic 训练与随机 Actor 相结合，并通过熵最大化目标进一步最大化该 Actor 的熵。我们发现，这能得到明显更加稳定且易于扩展的算法，在实践中的效率和最终性能均超过 DDPG。随机价值梯度的零步特例 SVG(0)(Heess et al., 2015)也可推导出类似方法，但 SVG(0) 优化的是标准最大期望回报目标，而且没有独立价值网络；我们发现，独立价值网络能够使训练更稳定。

最大熵强化学习通过优化策略，同时最大化期望回报和策略的期望熵。这一框架已用于多种场景，从逆强化学习(Ziebart et al., 2008)到最优控制(Todorov, 2008; Toussaint, 2009; Rawlik et al., 2012)。在引导策略搜索

(Levine & Koltun, 2013; Levine et al., 2016)中，最大熵分布用于引导策略学习趋向高奖励区域。近期，多篇论文指出了最大熵学习框架中 Q 学习与策略梯度方法之间的联系(O’ Donoghue et al., 2016; Haarnoja et al., 2017; Nachum et al., 2017a; Schulman et al., 2017a)。以往多数无模型工作假设动作空间离散；Nachum et al. (2017b) 用高斯分布近似最大熵分布，Haarnoja et al. (2017) 则训练采样网络，从最优策略中抽取样本。虽然 Haarnoja et al. (2017) 提出的软 Q 学习具有价值函数和 Actor 网络，它并非真正的 Actor-Critic 算法：Q 函数估计的是最优 Q 函数，Actor 除了通过数据分布之外，并不直接影响 Q 函数。因此，Haarnoja et al. (2017) 将 Actor 网络解释为近似采样器，而非 Actor-Critic 算法中的 Actor。关键在于，该方法能否收敛取决于采样器对真实后验的近似程度。相比之下，我们证明，无论采用何种策略参数化，所提方法都能收敛到给定策略类中的最优策略。此外，这些已有最大熵方法在从零学习时，通常无法超过 DDPG 等先进离策略算法，尽管它们可能改善探索并便于微调。实验表明，我们的 SAC 算法在性能上大幅超过了以往先进的离策略深度强化学习方法。

3. 预备知识

我们首先介绍记号，并概述标准强化学习和最大熵强化学习框架。

3.1. 记号

本文研究连续动作空间中的策略学习。考虑由元组$(\mathcal{S}, \mathcal{A}, p, r)$定义的无限时域马尔可夫决策过程(MDP)，其中状态空间 $\mathcal{S}$ 和动作空间 $\mathcal{A}$ 均为连续空间。未知的状态转移概率 $p : \mathcal{S} \times \mathcal{S} \times \mathcal{A} \rightarrow [0, \infty)$ 表示在给定当前状态 $\mathbf{s}_t \in \mathcal{S}$ 和动作 $\mathbf{a}_t \in \mathcal{A}$ 时，下一状态 $\mathbf{s}_{t+1} \in \mathcal{S}$ 的概率密度。环境在每次转移时产生有界奖励 $r : \mathcal{S} \times \mathcal{A} \rightarrow [r_{\min}, r_{\max}]$。我们用 $\rho_\pi(\mathbf{s}_t)$ 和 $\rho_\pi(\mathbf{s}_t, \mathbf{a}_t)$ 分别表示策略 $\pi(\mathbf{a}_t|\mathbf{s}_t)$ 所诱导轨迹分布的状态边缘分布和状态—动作边缘分布。

3.2. 最大熵强化学习

标准强化学习最大化期望累计奖励 $\sum_t \mathbb{E}_{(\mathbf{s}_t, \mathbf{a}_t) \sim \rho_\pi} [r(\mathbf{s}_t, \mathbf{a}_t)]$。我们考虑更一般的最大熵目标(例如 Ziebart (2010))：在目标中加入关于 $\rho_\pi(\mathbf{s}_t)$ 的策略期望熵，从而鼓励随机策略：

$$J(\pi) = \sum_{t=0}^{T} \mathbb{E}_{(\mathbf{s}_t, \mathbf{a}_t) \sim \rho_\pi} \left[r(\mathbf{s}_t, \mathbf{a}_t) + \alpha \mathcal{H}(\pi(\cdot\,|\mathbf{s}_t)) \right]. \quad (1)$$

温度参数 α 决定熵项相对于奖励项的重要程度，从而控制最优策略的随机性。最大熵目标与传统强化学习使用的最大期望奖励目标有所不同，但当 $\alpha \rightarrow 0$ 时，可以在极限意义下恢复传统目标。下文不再显式写出温度参数，因为通过将奖励乘以 α^{-1}，总能把温度吸收到奖励中。

这一目标具有多项概念和实践优势。首先，它鼓励策略更广泛地探索，同时放弃明显缺乏前景的方向。其次，策略能够捕捉近最优行为的多个模态。当多种动作看起来同样有吸引力时，策略会为这些动作分配相同的概率质量。最后，已有研究观察到该目标能够改善探索(Haarnoja et al., 2017; Schulman et al., 2017a)；我们的实验也表明，相较于优化传统强化学习目标的先进方法，它能显著提高学习速度。引入折扣因子 γ，使期望奖励与熵之和保持有限，即可将该目标扩展到无限时域问题。无限时域折扣情形下的最大熵目标表达更为复杂(Thomas, 2014)，详见附录 A。

已有方法提出直接求解最优 Q 函数，并据此恢复最优策略(Ziebart et al., 2008; Fox et al., 2016; Haarnoja et al., 2017)。我们将讨论如何通过策略迭代构造 SAC 算法：评估当前策略的 Q 函数，再通过离策略梯度更新改进策略。尽管传统强化学习中已有此类算法，但据我们所知，本文方法是最大熵强化学习框架下首个离策略 Actor-Critic 方法。

4. 从软策略迭代到 Soft Actor-Critic

我们的离策略 SAC 算法可由策略迭代的最大熵变体推导而来。我们首先给出推导，验证该算法能够收敛到所属概率密度类中的最优策略，随后给出

基于这一理论的实用深度强化学习算法。

4.1. 软策略迭代的推导

我们先推导软策略迭代。这是一种学习最优最大熵策略的通用算法，在最大熵框架中交替执行策略评估与策略改进。为便于理论分析并给出收敛保证，推导从表格型情形出发；下一节再扩展到一般连续情形。我们将证明，软策略迭代会收敛到给定策略集合中的最优策略，该集合例如可以是一组参数化概率密度。

在软策略迭代的策略评估步骤中，我们希望依据式 1 的最大熵目标计算策略 π 的价值。对于固定策略，可以从任意函数 $Q : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 出发，反复应用经过修改的贝尔曼备份算子 $\mathcal{T}^{\pi}$，迭代计算软 Q 值。该算子定义为

$$\mathcal{T}^{\pi} Q(\mathbf{s}_t, \mathbf{a}_t) \triangleq r(\mathbf{s}_t, \mathbf{a}_t) + \gamma \, \mathbb{E}_{\mathbf{s}_{t+1} \sim p}\left[V(\mathbf{s}_{t+1})\right], \quad (2)$$

其中，

$$V(\mathbf{s}_t) = \mathbb{E}_{\mathbf{a}_t \sim \pi}\left[Q(\mathbf{s}_t, \mathbf{a}_t) - \log \pi(\mathbf{a}_t | \mathbf{s}_t)\right] \quad (3)$$

为软状态价值函数。反复应用 $\mathcal{T}^{\pi}$，即可得到任意策略 π 的软价值函数，其形式化结论如下。

引理 1(软策略评估)。考虑式 2 中的软贝尔曼备份算子 $\mathcal{T}^{\pi}$，以及满足 $|\mathcal{A}| < \infty$ 的映射 $Q^0 : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$，定义 $Q^{k+1} = \mathcal{T}^{\pi} Q^k$。则当 $k \rightarrow \infty$ 时，序列 Q^k 收敛到策略 π 的软 Q 值。

证明。见附录 B.1。 □

在策略改进步骤中，我们将策略向新 Q 函数的指数形式更新。可以保证，这种更新会得到软价值更高的策略。由于实践中倾向于采用便于计算的策略，我们进一步将策略限制在集合 Π 中，例如高斯分布等参数化分布族。为满足约束 $\pi \in \Pi$，需要把改进后的策略投影到目标策略集合中。原则上可以选择任意投影，但采用基于 Kullback-Leibler 散度定义的信息投影会更方便。换言之，在策略改进步骤中，对每个状态按下式更新策略:

$$\pi_{\text{new}} = \arg\min_{\pi' \in \Pi} \mathrm{D}_{\mathrm{KL}}\left(\pi'(\cdot | \mathbf{s}_t) \,\middle\|\, \frac{\exp\left(Q^{\pi_{\text{old}}}(\mathbf{s}_t, \cdot)\right)}{Z^{\pi_{\text{old}}}(\mathbf{s}_t)}\right). \quad (4)$$

配分函数 $Z^{\pi_{\text{old}}}(\mathbf{s}_t)$ 用于归一化该分布。虽然它通常难以计算，但不会影响关于新策略的梯度，因此可以忽略，下一节将进一步说明。对于这一投影，我们可以证明，就式 1 的目标而言，投影后的新策略比旧策略具有更高价值。引理 2 给出形式化结论。

引理 2(软策略改进)。设 $\pi_{\text{old}} \in \Pi$，并令 π_{new} 为式 4 所定义最小化问题的最优解。当 $|\mathcal{A}| < \infty$ 时，对所有($\mathbf{s}_t, \mathbf{a}_t$)$\in \mathcal{S} \times \mathcal{A}$，都有 $Q^{\pi_{\text{new}}}(\mathbf{s}_t, \mathbf{a}_t) \geq Q^{\pi_{\text{old}}}(\mathbf{s}_t, \mathbf{a}_t)$。

证明。见附录 B.2。 □

完整的软策略迭代算法交替执行软策略评估与软策略改进。可以证明，它将收敛到策略集合 Π (定理 1) 中的最优最大熵策略。虽然该算法能够找到最优解，但只有在表格型情形下才能精确执行。因此，接下来将其近似用于连续域：此时需要用函数近似器表示 Q 值，而把两个步骤分别执行至收敛的计算成本过高。这一近似产生了新的实用算法，即软 Actor-Critic。

定理 1(软策略迭代)。从任意 $\pi \in \Pi$ 出发，反复执行软策略评估与软策略改进，将收敛到策略 π^*。假设 $|\mathcal{A}| < \infty$，则对所有 $\pi \in \Pi$ 以及($\mathbf{s}_t, \mathbf{a}_t$)$\in \mathcal{S} \times \mathcal{A}$，都有 $Q^{\pi^*}(\mathbf{s}_t, \mathbf{a}_t) \geq Q^{\pi}(\mathbf{s}_t, \mathbf{a}_t)$。

证明。见附录 B.3。 □

4.2. Soft Actor-Critic

如上所述，大规模连续域需要采用软策略迭代的实用近似。为此，我们对 Q 函数和策略都使用函数近似器，并通过随机梯度下降交替优化两个网络，而非将评估与改进分别执行至收敛。考虑参数化状态价值函数 $V_{\psi}(\mathbf{s}_t)$、软 Q 函数 $Q_{\theta}(\mathbf{s}_t, \mathbf{a}_t)$ 和便于计算的策略 $\pi_{\phi}(\mathbf{a}_t | \mathbf{s}_t)$。这些网络的参数为 ψ, θ 和 ϕ。例如，价值函数可用表达能力较强的神经网络建模，策略则可采用均值与协方差由神经网络给出的高斯分布。下面推导这些参数向量的更新规则。

状态价值函数用于近似软价值。原则上，无需为状态价值单独设置函数近似器，因为根据式 3，它与 Q 函数及策略相联系。这个量可以

通过从当前策略抽取一个动作样本来无偏估计，但在实践中，为软价值单独设置函数近似器能够稳定训练，也便于与其他网络同时训练。训练软价值函数时，最小化下列平方残差：

$$J_V(\psi) = \mathbb{E}_{\mathbf{s}_t \sim \mathcal{D}} \left[\frac{1}{2} \left(V_\psi(\mathbf{s}_t) - \mathbb{E}_{\mathbf{a}_t \sim \pi_\phi} \left[Q_\theta(\mathbf{s}_t, \mathbf{a}_t) - \log \pi_\phi(\mathbf{a}_t | \mathbf{s}_t) \right] \right)^2 \right] \tag{5}$$

其中，$\mathcal{D}$ 是此前采样的状态与动作的分布，也可视为经验回放缓冲区。式 5 的梯度可用下列无偏估计器估计：

$$\hat{\nabla}_\psi J_V(\psi) = \nabla_\psi V_\psi(\mathbf{s}_t) \left(V_\psi(\mathbf{s}_t) - Q_\theta(\mathbf{s}_t, \mathbf{a}_t) + \log \pi_\phi(\mathbf{a}_t | \mathbf{s}_t) \right), \tag{6}$$

其中，动作从当前策略采样，而非从经验回放缓冲区采样。软 Q 函数的参数通过最小化软贝尔曼残差来训练：

$$J_Q(\theta) = \mathbb{E}_{(\mathbf{s}_t, \mathbf{a}_t) \sim \mathcal{D}} \left[\frac{1}{2} \left(Q_\theta(\mathbf{s}_t, \mathbf{a}_t) - \hat{Q}(\mathbf{s}_t, \mathbf{a}_t) \right)^2 \right], \tag{7}$$

其中，

$$\hat{Q}(\mathbf{s}_t, \mathbf{a}_t) = r(\mathbf{s}_t, \mathbf{a}_t) + \gamma \, \mathbb{E}_{\mathbf{s}_{t+1} \sim p} \left[V_{\bar{\psi}}(\mathbf{s}_{t+1}) \right], \tag{8}$$

同样可以用随机梯度进行优化：

$$\hat{\nabla}_\theta J_Q(\theta) = \nabla_\theta Q_\theta(\mathbf{a}_t, \mathbf{s}_t) \left(Q_\theta(\mathbf{s}_t, \mathbf{a}_t) - r(\mathbf{s}_t, \mathbf{a}_t) - \gamma V_{\bar{\psi}}(\mathbf{s}_{t+1}) \right). \tag{9}$$

更新使用目标价值网络 $V_{\bar{\psi}}$，其中$\bar{\psi}$ 可以取为价值网络权重的指数移动平均。已有研究表明，这能稳定训练 (Mnih et al., 2015)。另一种做法是定期将目标权重更新为当前价值函数的权重(见附录 E)。最后，策略参数可通过直接最小化式 4 中的期望 KL 散度来学习：

$$J_\pi(\phi) = \mathbb{E}_{\mathbf{s}_t \sim \mathcal{D}} \left[\mathrm{D}_{\mathrm{KL}} \left(\pi_\phi(\cdot | \mathbf{s}_t) \,\middle\|\, \frac{\exp\left(Q_\theta(\mathbf{s}_t, \cdot) \right)}{Z_\theta(\mathbf{s}_t)} \right) \right]. \tag{10}$$

最小化 J_π 有多种方式。策略梯度方法的典型做法是使用似然比梯度估计器 (Williams, 1992)，它无需通过策略网络和目标密度网络反向传播梯度。然而，在本文中，目标密度是由神经网络表示的可微 Q 函数，因此采用重参数化技巧更为方便，并能得到方差较低的估计器。为此，我们通过神经网络变换对策略进行重参数化：

$$\mathbf{a}_t = f_\phi(\epsilon_t; \mathbf{s}_t), \tag{11}$$

Algorithm 1 Soft Actor-Critic

Initialize parameter vectors ψ, $\bar{\psi}$, θ, ϕ.
for each iteration **do**
  for each environment step **do**
    $\mathbf{a}_t \sim \pi_\phi(\mathbf{a}_t | \mathbf{s}_t)$
    $\mathbf{s}_{t+1} \sim p(\mathbf{s}_{t+1} | \mathbf{s}_t, \mathbf{a}_t)$
    $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{s}_t, \mathbf{a}_t, r(\mathbf{s}_t, \mathbf{a}_t), \mathbf{s}_{t+1})\}$
  end for
  for each gradient step **do**
    $\psi \leftarrow \psi - \lambda_V \hat{\nabla}_\psi J_V(\psi)$
    $\theta_i \leftarrow \theta_i - \lambda_Q \hat{\nabla}_{\theta_i} J_Q(\theta_i)$ for $i \in \{1, 2\}$
    $\phi \leftarrow \phi - \lambda_\pi \hat{\nabla}_\phi J_\pi(\phi)$
    $\bar{\psi} \leftarrow \tau \psi + (1 - \tau) \bar{\psi}$
  end for
end for

其中，ϵ_t 是从某个固定分布(例如球形高斯分布)采样的输入噪声向量。现在可以将式 10 的目标改写为

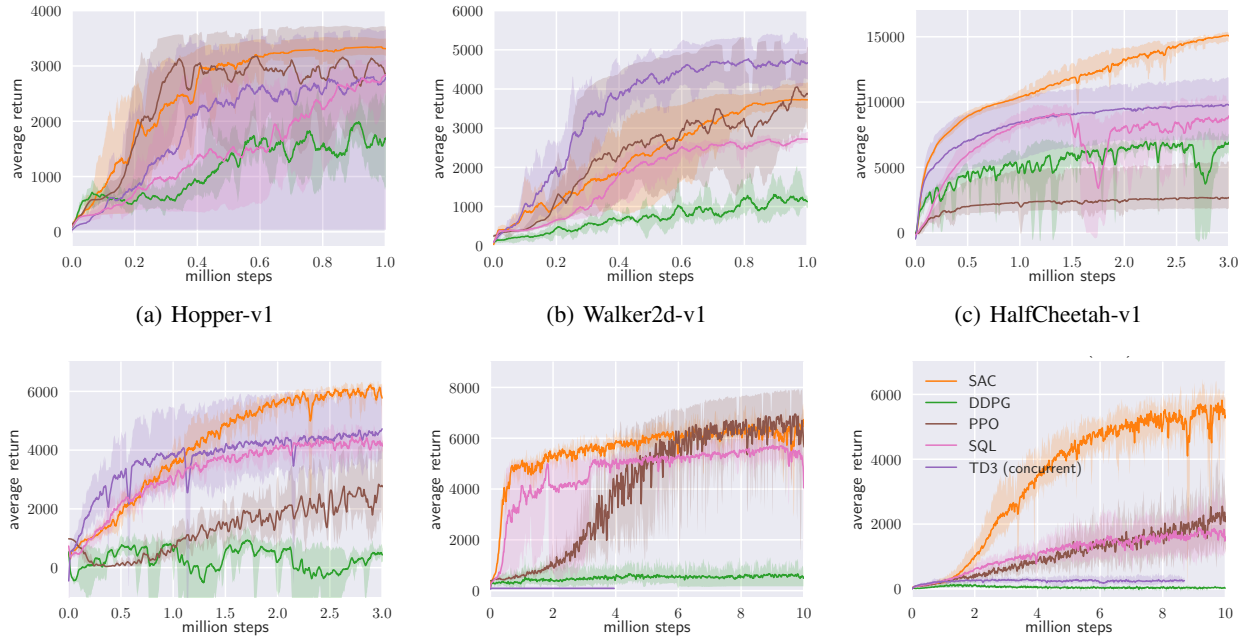
$$J_\pi(\phi) = \mathbb{E}_{\mathbf{s}_t \sim \mathcal{D}, \epsilon_t \sim \mathcal{N}} \left[\log \pi_\phi(f_\phi(\epsilon_t; \mathbf{s}_t) | \mathbf{s}_t) - Q_\theta(\mathbf{s}_t, f_\phi(\epsilon_t; \mathbf{s}_t)) \right], \tag{12}$$

其中，π_ϕ 由 f_ϕ 隐式定义。由于配分函数与 ϕ 无关，因此可以省略。式 12 的梯度可以近似为

$$\hat{\nabla}_\phi J_\pi(\phi) = \nabla_\phi \log \pi_\phi(\mathbf{a}_t | \mathbf{s}_t) + \left(\nabla_{\mathbf{a}_t} \log \pi_\phi(\mathbf{a}_t | \mathbf{s}_t) - \nabla_{\mathbf{a}_t} Q(\mathbf{s}_t, \mathbf{a}_t) \right) \nabla_\phi f_\phi(\epsilon_t; \mathbf{s}_t), \tag{13}$$

其中，$\mathbf{a}_t$ 在 $f_\phi(\epsilon_t$ 处计算；$\mathbf{s}_t)$。这一无偏梯度估计器将 DDPG 风格的策略梯度 (Lillicrap et al., 2015) 扩展到了任意便于计算的随机策略。

算法还采用两个 Q 函数，以减轻策略改进步骤中的正偏差；已有研究表明，这种偏差会降低基于价值的方法的性能 (Hasselt, 2010; Fujimoto et al., 2018)。具体而言，我们用参数 θ_i 表示两个 Q 函数，并独立训练它们以优化 $J_Q(\theta_i)$。然后，按照 Fujimoto et al. (2018) 的建议，在式 6 的价值梯度和式 13 的策略梯度中使用两个 Q 函数的较小值。虽然仅用一个 Q 函数也能学习包括 21 维 Humanoid 在内的复杂任务，但我们发现，采用两个 Q 函数能显著加快训练，尤其是在较难的任务上。完整算法见算法 1。该方法交替执行两步：用当前策略与环境交互、收集经验；从经验回放缓冲区采样批次，利用随机梯度更新函数近似器。实践中，每执行一个环境步，随后进行一次或多次梯度更新(全部超参数见附录 D



(a) Hopper-v1 (b) Walker2d-v1 (c) HalfCheetah-v1

(d) Ant-v1 (e) Humanoid-v1 (f) Humanoid (rllab)

图 1. 连续控制基准上的训练曲线。SAC(黄色)在所有任务上都表现稳定，并在最具挑战性的任务上优于同策略和离策略方法。

)。使用经验回放缓冲区中的离策略数据是可行的，因为价值估计器与策略都可以完全采用离策略数据进行训练。只要能对任意状态—动作元组计算策略，该算法就不依赖于具体的策略参数化形式。

5. 实验

实验旨在比较所提方法与以往同策略、离策略深度强化学习算法的样本复杂度及稳定性。我们在 OpenAI Gym 基准中的多种复杂连续控制任务 (Brockman et al., 2016)，以及 rllab 实现的 Humanoid 任务 (Duan et al., 2016) 上进行比较。多种算法都能解决较容易的任务，但对 21 维 Humanoid(rllab)等复杂基准而言，离策略算法尤其难以取得良好结果 (Duan et al., 2016)。算法稳定性也显著影响性能：在简单任务中，通过调节超参数获得良好结果较为可行；而在最难的基准上，敏感算法原本就很窄的有效超参数区域会变得极其狭小，从而导致较差性能 (Gu et al., 2016)。

我们将所提方法与深度确定性策略梯度 (DDPG)(Lillicrap et al., 2015) 比较，该算法被视为效率较高的离策略深度强化学习方法之一 (Duan et al., 2016)；也与稳定有效的同策略策略梯度算法 PPO (Schulman et al., 2017b)，以及用于学习最大熵策略的近期离策略算法软 Q 学习(SQL)(Haarnoja et al., 2017) 比较。我们的 SQL 实现同样包含两个 Q 函数，这能改善其在多数环境中的表现。此外，我们采用作者提供的实现，与同期提出的 TD3 算法 (Fujimoto et al., 2018) 比较。该方法扩展了 DDPG，首次将双 Q 学习技巧用于连续控制，并作出了其他改进。附录 E 还包含 Trust-PCL (Nachum et al., 2017b) 及另外两种 SAC 变体。评估 DDPG 和 PPO 时，我们关闭探索噪声。对于不显式注入探索噪声的最大熵算法，我们在评估 SQL 时保留探索噪声，在评估 SAC 时采用均值动作。SAC 实现的源代码[1]和视频[2]均已在线公开。

[1] github.com/haarnoja/sac
[2] sites.google.com/view/soft-actor-critic

5.1. 对比评估

图 1 展示了 DDPG、PPO 和 TD3 在训练期间评估轨迹的总平均回报。对每种算法，我们采用不同随机种子训练五个实例，每隔 1000 个环境步执行一次评估。实线表示五次试验的均值，阴影表示最小回报与最大回报之间的范围。

总体而言，SAC 在简单任务上的表现与基线相当，而在较难任务上的学习速度和最终性能均大幅超过基线。例如，DDPG 在 Ant-v1、Humanoid-v1 和 Humanoid(rllab)上均未取得进展，已有工作也报告了相同现象 (Gu et al., 2016; Duan et al., 2016)。SAC 的学习速度也明显快于 PPO，因为 PPO 在高维复杂任务上需要很大的批次才能稳定学习。另一种最大熵强化学习算法 SQL 也能学会所有任务，但速度更慢，渐近性能也较差。SAC 的定量结果与已有工作报告的其他方法相比，同样具有明显优势 (Duan et al., 2016; Gu et al., 2016; Henderson et al., 2017)，表明其在这些基准上的样本效率与最终性能超过了当时的先进水平。实验中 SAC 使用的全部超参数见附录 D。

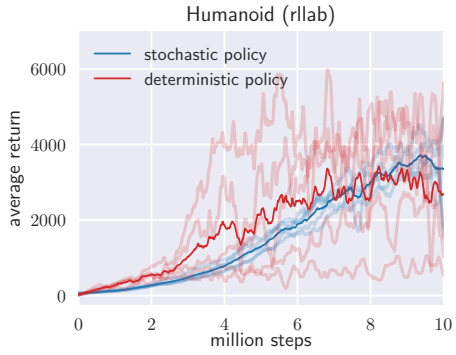


图 2. 在 Humanoid(rllab)基准上，比较 SAC(蓝色)及其确定性变体(红色)在各随机种子下的稳定性。确定性策略在不同种子间的差异明显增大，说明随机性有助于稳定训练。

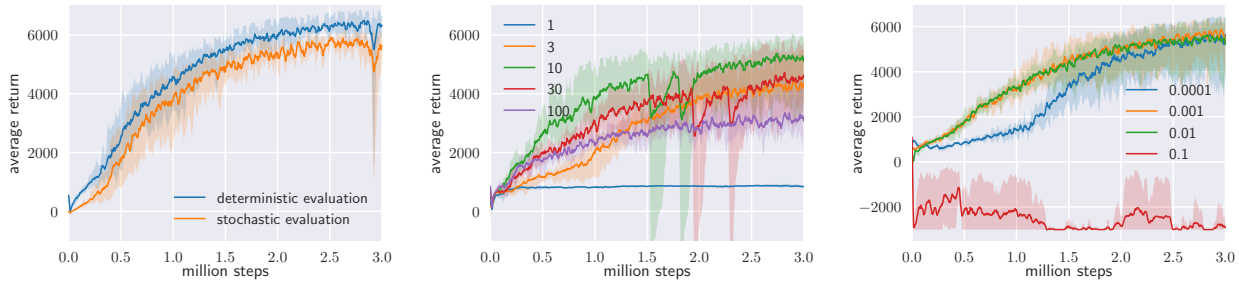
5.2. 消融研究

上一节结果表明，基于最大熵原理的算法能够在 Humanoid 等复杂任务上超过传统强化学习方法。本节进一步分析 SAC 的哪些组成部分对于良好性能至关重要，并检验 SAC 对两个关键超参数的敏感性：奖励缩放和目标价值更新的平滑常数。

随机策略与确定性策略。SAC 通过最大熵目标学习随机策略，熵同时出现在策略函数和价值函数中。在策略中，熵可以防止策略方差过早收敛(式 10)；在价值函数中，它通过提高通向高熵行为的状态区域的价值来促进探索(式 5)。为比较策略随机性和熵最大化对性能的影响，我们构造了一种不最大化熵的确定性 SAC 变体。它与 DDPG 很接近，但采用两个 Q 函数、硬目标更新、没有独立的目标 Actor，并使用固定的探索噪声，而非学习噪声。图 2 比较了两个变体各五次独立运行的结果，运行采用不同的随机种子进行初始化。SAC 的表现更加一致，而确定性变体在不同种子间的差异很大，表明稳定性明显较差。从图中可以看出，通过熵最大化学习随机策略，能够显著稳定训练。这对于超参数难以调节的复杂任务尤其重要。在该对比中，我们采用硬更新：定期将当前价值网络的权重复制到目标价值网络(所有基准上的平均性能对比见附录 E)。

策略评估。由于 SAC 收敛到随机策略，为获得最佳性能，最终评估时采用确定性策略通常更有利。我们选择策略分布的均值来近似最大后验动作。图 3(a) 比较了训练回报与按此方式得到的评估回报，表明确定性评估能够取得更好性能。所有训练曲线展示的都是奖励之和；它与 SAC、SQL、Trust-PCL 等最大熵强化学习算法实际优化的目标不同，后者还要最大化策略熵。

奖励尺度。SAC 对奖励信号的缩放尤其敏感，因为它起到基于能量的最优策略温度参数的作用，从而控制策略随机性。较大的奖励幅度对应较低的熵。图 3(b) 展示了改变奖励尺度时的学习表现：奖励幅度较小时，策略接近均匀分布，无法充分利用奖励信号，因而性能明显下降；奖励幅度较大时，模型起初学习较快，



(a) Evaluation (b) Reward Scale (c) Target Smoothing Coefficient (τ)

图 3. SAC 在 Ant-v1 任务上对若干超参数的敏感性。(a) 采用均值动作评估，通常能获得更高回报。训练时策略还会最大化熵，而均值动作一般并不对应最大回报目标下的最优动作。(b) 奖励尺度与最优策略的温度有关，因此 SAC 对奖励缩放敏感。不同环境的最优奖励尺度不同，需要分别调节。(c) 目标价值平滑系数 τ 用于稳定训练。目标变化过快(τ 较大)可能导致不稳定(红色)；目标变化较慢(τ 较小)则会减缓学习(蓝色)。

但随后策略会变得近乎确定，并因探索不足而陷入较差的局部极小值。合适的奖励缩放能平衡探索与利用，从而加快学习并改善渐近性能。实践中，我们发现奖励尺度是唯一需要调节的超参数；将其自然地解释为最大熵框架中温度的倒数，有助于直观判断该如何调整。

目标网络更新。常见做法是设置独立目标价值网络，使其缓慢跟踪实际价值函数，以提高稳定性。与已有工作相同，我们采用平滑常数为 τ 的指数移动平均更新目标价值网络权重 (Lillicrap et al., 2015; Mnih et al., 2015)。取一时，相当于每轮直接复制权重的硬更新；取零时，目标网络完全不更新。图 3(c) 比较了改变 τ 时 SAC 的表现：τ 较大可能导致不稳定，τ 较小则可能减缓训练。不过，τ 的合适取值范围相对较宽，我们在所有任务上均使用同一取值(0.005)。附录 E 的图 4 还比较了另一种 SAC 变体：不用指数移动平均，而是每隔 1000 次梯度更新，将当前网络权重直接复制到目标网络。我们发现，在环境步之间执行多次梯度更新有利于这一变体，可以提高性能，但也会增加计算成本。

6. 结论

本文提出软 Actor-Critic(SAC)：一种离策略最大熵深度强化学习算法，兼具较高样本效率、熵最大化的优势与训练稳定性。理论上，我们推导了软策略迭代，并证明其收敛到最优策略。在此基础上构造 SAC 算法，实验表明，它优于当时先进的无模型深度强化学习方法，包括离策略 DDPG 和同策略 PPO。其样本效率也大幅超过 DDPG。结果表明，采用随机策略并最大化熵的强化学习算法，是提高鲁棒性和稳定性的有前景方向。后续值得进一步研究最大熵方法，包括引入二阶信息，例如信赖域 (Schulman et al., 2015)，或采用表达能力更强的策略类。

致谢

感谢 Vitchyr Pong 提供富有启发的讨论、协助实现算法，并提供 DDPG 基线代码；感谢 Ofir Nachum 协助运行 Trust-PCL 实验；感谢 George Tucker 对论文早期版本提出宝贵意见。本研究得到 Siemens 和 Berkeley DeepDrive 的支持。

参考文献

Barto, A. G., Sutton, R. S., and Anderson, C. W. 能够解决复杂学习控制问题的类神经元自适应单元。IEEE trans actions on systems, man, and cybernetics, pp. 834–846, 19 83.

Bhatnagar, S., Precup, D., Silver, D., Sutton, R. S., Maei, H. R., and Szepesvári, C. 采用任意光滑函数近似的收敛时序差分学习。In Advances in Neural Information Proce ssing Systems (NIPS), pp. 1204–1212, 2009.

Brockman, G., Cheung, V., Pettersson, L., Schneider, J., S chulman, J., Tang, J., and Zaremba, W. OpenAI Gym。ar Xiv preprint arXiv:1606.01540, 2016.

Duan, Y., Chen, X. Houthooft, R., Schulman, J., and Abbe el, P. 连续控制中的深度强化学习基准评测。In Internati onal Conference on Machine Learning (ICML), 2016.

Fox, R., Pakman, A., and Tishby, N. 通过软更新抑制强化学习中的噪声。In Conference on Uncertainty in Artifi cial Intelligence (UAI), 2016.

Fujimoto, S., van Hoof, H., and Meger, D. 处理 Actor-Crit ic 方法中的函数近似误差。arXiv preprint arXiv:1802.09 477, 2018.

Gruslys, A., Azar, M. G., Bellemare, M. G., and Munos, R. Reactor：一种高样本效率的 Actor-Critic 架构。arXiv p reprint arXiv:1704.04651, 2017.

Gu, S., Lillicrap, T., Ghahramani, Z., Turner, R. E., and Le vine, S. Q-prop：采用离策略 Critic 的高样本效率策略梯度。arXiv preprint arXiv:1611.02247, 2016.

Haarnoja, T., Tang, H., Abbeel, P., and Levine, S. 采用深度能量策略的强化学习。In International Conference on Machine Learning (ICML), pp. 1352–1361, 2017.

Hasselt, H. V. 双 Q 学习。In Advances in Neural Informa tion Processing Systems (NIPS), pp. 2613–2621, 2010.

Heess, N., Wayne, G., Silver, D., Lillicrap, T., Erez, T., an d Tassa, Y. 通过随机价值梯度学习连续控制策略。In A dvances in Neural Information Processing Systems (NIPS), pp. 2944–2952, 2015.

Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., and Meger, D. 深度强化学习中真正重要的因素。ar Xiv preprint arXiv:1709.06560, 2017.

Kingma, D. and Ba, J. Adam：一种随机优化方法。In In ternational Conference for Learning Presentations (ICLR), 2015.

Levine, S. and Koltun, V. 引导策略搜索。In International Conference on Machine Learning (ICML), pp. 1–9, 2013.

Levine, S., Finn, C., Darrell, T., and Abbeel, P. 深度视觉运动策略的端到端训练。Journal of Machine Learning R esearch, 17(39):1–40, 2016.

Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., Silver, D., and Wierstra, D. 采用深度强化学习的连续控制。arXiv preprint arXiv:1509.02971, 2015.

Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antono glou, I., Wierstra, D., and Riedmiller, M. 使用深度强化学习玩 Atari 游戏。arXiv preprint arXiv:1312.5602, 2013.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Venes s, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjela nd, A. K., Ostrovski, G., et al. 通过深度强化学习实现人类水平的控制。Nature, 518(7540): 529–533, 2015.

Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T. P., Harley, T., Silver, D., and Kavukcuoglu, K. 深度强化学习的异步方法。In International Conference on Machin e Learning (ICML), 2016.

Nachum, O., Norouzi, M., Xu, K., and Schuurmans, D. 弥合基于价值与基于策略的强化学习之间的差距。In Ad vances in Neural Information Processing Systems (NIPS), pp. 2772–2782, 2017a.

Nachum, O., Norouzi, M., Xu, K., and Schuurmans, D. Tr ust-PCL：用于连续控制的离策略信赖域方法。arXiv pr eprint arXiv:1707.01891, 2017b.

O’Donoghue, B., Munos, R., Kavukcuoglu, K., and Mnih , V. PGQ：结合策略梯度与 Q 学习。arXiv preprint arXi v:1611.01626, 2016.

Peters, J. and Schaal, S. 利用策略梯度对运动技能进行强化学习。Neural networks, 21(4):682– 697, 2008.

Rawlik, K., Toussaint, M., and Vijayakumar, S. 通过近似推断进行随机最优控制与强化学习。Robotics: Science and Systems (RSS), 2012.

Schulman, J., Levine, S., Abbeel, P., Jordan, M. I., and Mo ritz, P. 信赖域策略优化。In International Conference on Machine Learning (ICML), pp. 1889–1897, 2015.

Schulman, J., Abbeel, P., and Chen, X. 策略梯度与软 Q 学习的等价性。arXiv preprint arXiv:1704.06440, 2017a.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. 近端策略优化算法。arXiv preprint arXiv:1707.06347, 2017b.

Silver, D., Lever, G., Heess, N., Degris, T., Wierstra, D., and Riedmiller, M. 确定性策略梯度算法。In International Conference on Machine Learning (ICML), 2014.

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., Dieleman, S., Grewe, D., Nham, J., Kalchbrenner, N., Sutskever, I., Lillicrap, T., Leach, M., Kavukcuoglu, K., Graepel, T., and Hassabis, D. 通过深度神经网络和树搜索掌握围棋。Nature, 529(7587):484–489, Jan 2016. ISSN 0028-0836. Article.

Sutton, R. S. and Barto, A. G. 强化学习导论，第 1 卷。MIT press Cambridge, 1998.

Thomas, P. 自然 Actor-Critic 算法中的偏差。In International Conference on Machine Learning (ICML), pp. 441–448, 2014.

Todorov, E. 最优控制与估计之间的一般对偶性。In IEEE Conference on Decision and Control (CDC), pp. 4286–4292. IEEE, 2008.

Toussaint, M. 利用近似推断进行机器人轨迹优化。In International Conference on Machine Learning (ICML), pp. 1049–1056. ACM, 2009.

Williams, R. J. 用于联结主义强化学习的简单统计梯度跟随算法。Machine learning, 8(3-4):229–256, 1992.

Ziebart, B. D. 利用最大因果熵原理对有目的的自适应行为建模。Carnegie Mellon University, 2010.

Ziebart, B. D., Maas, A. L., Bagnell, J. A., and Dey, A. K. 最大熵逆强化学习。In AAAI Conference on Artificial Intelligence (AAAI), pp. 1433–1438, 2008.